

**APOYO EN EL MANEJO Y PUBLICACIÓN DE DATOS SOBRE BIODIVERSIDAD
PARA EL CERTIFICADO DE REPORTE A TRAVÉS DEL SIB COLOMBIA (CR-SIB)
ASOCIADO A LA NORMATIVIDAD DE LOS PERMISOS DE RECOLECCIÓN
ESTABLECIDOS EN LOS DECRETOS 1376 Y 3016 DE 2013.**

Permisos de Recolección de especímenes de especies silvestres de la diversidad biológica.

Autor:

JUAN CAMILO ESPINOSA MURILLO

Directora Interna

Martha Cecilia Gutiérrez Sarmiento

Licenciada en Biología msc.

Universidad Distrital Francisco José de Caldas

Directora Externa:

Camila Andrea Plata Corredor

Ingeniera Ambiental / Bióloga

Investigadora Asistente

Sistema de Información Sobre Biodiversidad de Colombia.

Facultad de Medio Ambiente y Recursos Naturales

Universidad Distrital Francisco José de Caldas

Ingeniería ambiental

Bogotá D. C 2019

Agradecimientos

Quiero agradecer al Equipo de Coordinación SiB Colombia, a Camila Plata Corredor, Jeimmy Díaz y a la Docente Martha Gutiérrez por orientarme y brindarme las herramientas necesarias en el desarrollo del proyecto de pasantía, así mismo expresó un gran sentimiento de gratitud con la Universidad Distrital Francisco José de Caldas y con el Instituto de Investigaciones de Recursos Biológicos Alexander von Humboldt.

Agradezco a mi Familia y amigos, quienes me brindaron su ayuda durante toda mi preparación profesional en mi alma máter la Universidad Distrital Francisco José de Caldas.



Contenido

1. Introducción	3
2. Planteamiento del problema y justificación	4
3. Antecedentes	4
4. Metodología	5
4.1 Contextualización en normatividad y estándares de publicación.	5
4.2 Migración de recursos.	5
5. Resultados.	17
6. Discusión y Conclusiones	21
7. Recomendaciones	22
8. Metas e indicadores	23
9. Referencias	24
Anexos	25

1. Introducción

El Sistema de Información sobre Biodiversidad de Colombia (SiB Colombia) se establece con el Decreto 1603 de 1994 en el marco del proceso de creación del Sistema Nacional Ambiental (SINA) con la Ley 99 de 1993. El SiB Colombia tiene como objetivo principal facilitar la gestión de datos e información sobre biodiversidad, basándose en el libre acceso a los datos por parte del público y así permitiendo el acceso a la información de una gran variedad de audiencias. Dicha gestión y manejo de la información permite establecer una base de datos sobre biodiversidad más completa, la cual es una herramienta de apoyo científico y técnico en la toma de decisiones de proyectos investigativos en relación a la conservación, el uso sostenible de la biodiversidad, y los servicios ecosistémicos (SiB Colombia, 2016).

Para lograr su objetivo el SiB Colombia cuenta con dos modelos de publicación: en primer lugar cuenta con un modelo de publicación basado en el libre acceso, datos abiertos y ciencia colaborativa este representa el modelo de publicación principal, en segundo lugar, cuenta con un modelo de publicación de datos Certificado de Reporte (CR.SiB) asociado a la normativa de recolección de especímenes de especies de la diversidad biológica, atendiendo a lo establecido en el Capítulo II - artículo No. 09 – inciso e) del Decreto 1376 de 2013 “Por el cual se reglamenta el permiso de estudio para la recolección de especímenes de especies silvestres de la diversidad biológica con fines investigación científica No comercial”, y da cumplimiento, además al artículo 06 del numeral 06 del Decreto 3016 de 2013 “Por el cual se reglamenta el permiso de estudio para la recolección de especímenes de especies silvestres de la diversidad biológica con fines de Elaboración de estudios ambientales” (SiB Colombia, 2018a).

Ambos Decretos establecen como obligación del titular solicitante del permiso, reportar al Sistema de Información sobre Biodiversidad de Colombia toda la información asociada a los especímenes recolectados y entregar a la autoridad ambiental el certificado de reporte emitido por dicho sistema (Ministerio de Ambiente y Desarrollo Sostenible, 2013); en la actualidad estos dos Decretos están compilados en el Decreto 1076 de 2015.

Aunque ambos modelos de publicación son homólogos, CR.SiB tiene diferencias relevantes en cuanto a la integración, validación y visibilización los datos en el SiB Colombia, algunas de las más importantes son:

- El modelo de reporte de datos asociados a permisos de recolección es un modelo 100% autónomo y no cuenta con un acompañamiento por parte del EC-SiB en la validación de estructura y calidad de los datos; caso contrario al modelo voluntario de publicación donde los publicadores tienen un acompañamiento efectivo y constante del EC-SiB en el proceso
- Los datos publicados a través de CR.SiB no son visibles a través de los canales de participación del SiB Colombia (biodiversidad.co) y tampoco aportan las cifras entregadas por el SiB Colombia para fines de conocer el estado de la biodiversidad nacional.

Los datos publicados a través del modelo de publicación CR-SiB no son datos abiertos dado que hacen uso de una licencia de privacidad restrictiva, además estos datos no son publicados a través de GBIF, sumado a esto la calidad de los datos reportados allí no es óptima para ser utilizada por el público (SiB Colombia, 2018b); por esta razón, en actualidad el Equipo coordinador del SiB Colombia

(EC-SiB) está realizando la migración de los recursos contenidos en el modelos de publicación CR-SiB al modelos de publicación SiB, permitiendo así que los datos sean abiertos y tengan una mayor visibilidad a nivel nacional, así mismo se busca consolidar en una misma base de datos toda la información sobre biodiversidad reportada a través de SiB Colombia. En el proceso de acompañamiento en la validación y migración de datos se desenvuelve la presente pasantía , cuyos **objetivos** son: 1) Utilizar el marco normativo asociado a los Decretos 1376 y 3016 de 2013, y los estándares Darwin Core (DwC) para la estructuración y publicación de datos sobre biodiversidad biológica, 2) Desarrollar la validación, limpieza y migración de los conjuntos de datos sobre biodiversidad pertenecientes a la Universidad de Pamplona y Universidad de Magdalena asociados a la normativa ambiental de los Decretos 1376 y 3016 de 2013, desde el modelo CR-SiB al modelo de publicación SiB Colombia, 3) desarrollar los documentos relacionados con el reporte de datos migrados y la metodología para revisión y validación de calidad de datos.

2. Planteamiento del problema y justificación

La plataforma de publicación CR-SiB cuenta con más de un millón de registros biológicos asociados a los Decretos 1376 y 3016 de 2013, los cuales están en más de 2000 recursos (<https://ipt.biodiversidad.co/cr-sib/>). A partir del diagnóstico de calidad de los 498.718 registros biológicos publicados en CR-SiB para el periodo 2014-2016 se identificó que el 39% de los 41 elementos evaluados se documentaron con una calidad regular, el 36.5% con una calidad mala y el 19.5% con una calidad muy mala (SiB Colombia, 2018b).

Dada la baja calidad de los datos es necesario realizar un proceso de migración de los recursos que busca mejorar la calidad y visibilidad de la información sobre biodiversidad, los datos migrados al modelo SiB Colombia se convierten en datos abiertos y de libre acceso, sumado a esto la información sobre biodiversidad hará parte de las bases de datos mediadas por GBIF, lo cual permitirá que los datos sean utilizados a nivel nacional e internacional. La revisión científica realizada por GBIF para el año 2018 encontró que en 98 países se realizaron artículos científicos los cuales hicieron uso de datos mediados por GBIF, siendo Colombia el país número 12 con mayor uso de estos datos, realizando la publicación de 29 artículos científicos (GBIF Secretariat, 2019).

Los datos publicados a través del SiB Colombia se convierten en una herramienta fundamental que permitirán la elaboración de líneas base consistentes en diferentes estudios ambientales, esto contribuye al desarrollo de los objetivos de La Política de Gobierno Digital cuyos lineamientos están establecidos en el Decreto 1008 de 2018 “Por la cual se establecen los lineamientos generales de la política de Gobierno Digital y se subroga el capítulo 1 del título 9 de la parte 2 del libro 2 del Decreto 1078 de 2015” la cual tiene por objetivo principal hacer uso y aprovechamiento de las tecnologías de información y comunicación (TIC) (Ministerio de Tecnologías de la Información y Comunicaciones, 2018).

3. Antecedentes

Al cierre del año 2018 el modelo de publicación CR.SiB contaba con más de un millón de registros biológicos asociados a los Decretos 1376 y 3016 de 2013, los cuales están en más de 2000 recursos disponibles en la plataforma CR-SiB: <https://ipt.biodiversidad.co/cr-sib/> (SiB Colombia, 2018a). La actividad de publicación a través del CR-SiB entre los años 2014-2018 fue realizada por 260 entidades, de las cuales el 73% son empresas dedicadas a la actividad de consultoría, el resto son personas naturales y universidades, el crecimiento en el reporte de datos ha proporcionado una

cantidad considerable de información que necesita ser migrada desde el modelo de publicación CR-SiB a al modelo de publicación SiB Colombia, para así aumentar la calidad y visibilidad de los datos (SiB Colombia, 2018a).

En el año 2018 se realizó un diagnóstico exploratorio general sobre la calidad de los datos publicados a través de CR-SiB durante el periodo 2014-2016, dicho diagnóstico tenía por objetivo determinar la calidad con la que son registrados 41 elementos del estándar Darwin Core (DwC), dicho estándar es utilizado para registrar información específica relacionada con un individuo o una especie de la biodiversidad, para esto se basaron en el la evaluación del parámetro de calidad de completitud con el que se documentaron los registros biológicos (SiB Colombia, 2018b). Este estudio tomó como fuente de datos la herramienta de publicación IPT CR-SiB, de allí se extrajeron un total de 498.718 registros para realizar la revisión de calidad, mostrando que el 39% de los elementos fueron registrados con una calidad regular, el 36.5% con una calidad mala y el 19.5% con una calidad muy mala (SiB Colombia, 2018b).

4. Metodología

El proceso metodológico se basa en la validación, migración y publicación de los datos en el modelo SiB, para lograr publicar los datos bajo los niveles de calidad deseados, es necesario validar el nivel de cumplimiento de los estándares Darwin Core (DwC), este es un marco de trabajo estable, sencillo y flexible para recopilar datos e información sobre biodiversidad provenientes de diversas fuentes, este desempeña un papel fundamental cuando se trata de compartir y usar datos de libre acceso sobre biodiversidad (Global Biodiversity Information Facility b, s.f.); así mismo el SiB-Colombia adopta los estándares GBIF Metadata Profile para la consolidación y publicación de metadatos estandarizados (SiB Colombia, 2018a).

4.1 Contextualización en normatividad y estándares de publicación.

Inicialmente se realizó una contextualización en la normatividad asociada al proceso de migración de datos entre los modelos de publicación CR.SiB y SiB Colombia, más específicamente sobre los decretos 1376 y 3016 de 2013, en la *tabla 04*. se presenta la normatividad consultada y los elementos de mayor relevancia. También se realizó la contextualización sobre los estándares de publicación, herramientas de validación y limpieza de datos, y los modelos de publicación del SiB Colombia.

4.2 Migración de recursos.

Se realizó el acompañamiento a la Universidad de Pamplona para realizar la migración de 11 conjuntos de datos, y el acompañamiento en la publicación de otros 4 conjuntos marcados con (*) en el *anexo 01*, de estos 4 conjuntos, 3 fueron seleccionados ya que requerían el certificado de reporte obtenido a partir de la publicación en CR-SiB, finalmente se tiene una totalidad de 15 conjuntos de datos distribuidos en 2 colecciones biológicas con un total de 4283 registros biológicos.

Así mismo se realizó el acompañamiento a la Universidad de Magdalena en la migración de 2 recursos: Onicóforos de la Sierra Nevada de Santa Marta con 4 registros biológicos y Tardígrados del Centro de Colecciones Biológicas de la Universidad del Magdalena CBUMAG con 11360 registro biológicos, para un total de 11364 registros biológicos.

Proceso de migración de datos




Figura 01. Esquema General del proceso de migración de datos

Exportación y ajustes de datos CR-SiB

Inicialmente el recurso es extraído el IPT CR-SiB (<https://ipt.biodiversidad.co/cr-sib/>), allí se descarga el archivo en formato Darwin Core Archive (dwc-a) que contiene tres archivos: eml.xml y meta.xml correspondientes a los metadatos y occurrence.txt el cual contiene los datos sobre biodiversidad, este último archivo se carga en el programa OpenRefine para realizar los ajustes mínimos sobre los datos, tales como: errores de tipeo, corrección de formato o modificación de identificadores duplicados, una vez son aplicados estos ajustes mínimos se obtienen los datos originales sobre los cuales se aplicarán los scripts de validación.

Validación de calidad

Haciendo uso del programa OpenRefine se aplican los scripts de validación disponibles en el repositorio de Github de SiB Colombia (SiB Colombia, 2019); dichos scripts están dirigidos a diferentes categorías de información de los datos: taxonómica, geográfica y fechas. realizando una comparación de la información registrada con bases de información oficiales de cada categoría:

- Taxonómica: Es comparada con la base de datos sobre biodiversidad GBIF¹

¹ https://github.com/SiB-Colombia/data-quality-open-refine/blob/master/ValTaxonomicAPIGBIF_ValTaxonomicAPIGBIF.txt

- Nombres geopolíticos: Son comparadas con la División Político-Administrativa de Colombia (DIVIPOLA)².
- Coordenadas: Son validadas y transformadas a sistema decimal haciendo uso del servicio web de Canadensys³, y la coherencia de la georreferenciación se valida haciendo uso del programa Quantum GIS (QGIS), a partir de esta validación en QGIS se obtiene la columna “countyValidación” utilizada en el script de cuantificación de calidad aparente.
- Temporal: Las fechas se validan por medio del API de Canadensys el cual verifica la coherencia del formato estándar de Darwin Core(SiB Colombia, 2019b), en este proceso se obtiene la columna eventData ISO utilizada en el script de cuantificación de calidad aparente⁴.

Los scripts de información taxonómica y geográfica aplicados, realizan una validación de tipo booleana, es decir, arroja valores de 1 para las validaciones correctas y 0 para las incorrectas, los valores de validación son documentados en una serie de columnas de validación, identificadas en su nombre con la palabra “Validation”, estas columnas son utilizadas en el Script de cuantificación de la calidad aparente de los datos. A las columnas spValidation, spcValidation y spcmValidation obtenidas en la validación de nombres geopolíticos, se les debe asignar el nombre stateProvValidationDIVIPOLA, countyValidationDIVIPOLA y municipalityValidationDIVIPOLA respectivamente.

Ajustes de formato y reporte de calidad

Los scripts de validación generan una sugerencia de ajuste para las validaciones incorrectas, estas son enviadas a los publicadores por medio de un reporte de calidad y revisión de los datos, son los publicadores quienes decidirán si estas sugerencias son aceptadas o no, en las sugerencias donde se trate de un error de tipeo, ortográfico o de formato, serán ajustadas directamente por el EC-SiB.

Limpieza de los datos

Una vez el publicador decide cuales sugerencias son aceptadas se realizan los correspondientes ajustes sobre los datos, finalmente se obtienen los datos procesados, los cuales serán publicados en el modelo SiB Colombia. Sobre estos datos se aplicará por segunda vez los scripts de validación, para esto es necesario eliminar todas las columnas de validación en el programa open refine y aplicar nuevamente los scripts.

Calidad aparente

La calidad aparente se determina por medio de un Script desarrollado en lenguaje Python, el cual se aplica sobre datos originales y procesados, los cuales deben ser cargados en formato Excel (.xls o .xlsx) y estar bajo el formato correcto del estándar DwC, Es necesario validar el mínimo de columnas establecido en el script, y eliminar todas las validaciones Booleanas que se hayan ejecutado sobre celdas vacías. A partir de la aplicación del script se obtiene el Índice de Calidad Aparente (ICA) de

² https://github.com/SiB-Colombia/data-quality-open-refine/blob/master/ValNamesGeo_ValNombresGeo.txt

³ <https://data.canadensys.net/tools/coordinates>

⁴ https://github.com/SiB-Colombia/data-quality-open-refine/blob/master/DateTransform_TransformFechas.txt

ambos conjuntos de datos y su respectivo porcentaje (%) de mejora, acompañados de 4 gráficos comparativos.

Índice de calidad Aparente

A partir de las plantillas estándar Darwin Core 2013 CR.SiB (SiB Colombia b) y Darwin Core 2015 (SiB Colombia c); se seleccionan los elementos DwC obligatorios, los cuales son agrupados en 4 categorías (tabla 01): registro, temporal, geográfica y taxonómica, a estos elementos se les mide los parámetros de calidad, completitud, precisión y coherencia, a partir de estos parámetros y categorías se calcula el Índice de Calidad Aparente (ICA) (Fórmula 17). Se denomina “Aparente” por el hecho que teóricamente los datos pueden tener un ICA máximo al mismo tiempo que sus registros sean un pobre reflejo de la realidad que representan (GBIF España, 2017).

Los parámetros de calidad no son medidos a todos los elementos DwC, ya que los formatos estándar y métodos de validación no son los mismos para todos los elementos, por esta misma razón, las definiciones de coherencia y precisión varían según el elemento DwC como se muestra en la Tabla 02.

Tabla 01. Parámetros de calidad medidos para cada Elemento DwC.

Categoría DwC	Elemento DwC	Parámetro de Calidad		
		Complejitud	Precisión	Coherencia
Registro	basisOfRecord	X	-	X
	institutionCode	X	-	-
	collectionCode	X	-	-
	institutionID	X	-	X
	collectionID	X	-	-
	occurrenceID	X	-	X
	catalogNumber	X	-	-
	otherCatalogNumbers	X	-	-
	preparations	X	-	-
	recordedBy	X	-	-
Temporal	eventDate	X	X	X
Geográfica	geodeticDatum	X	-	-
	minimumElevationInMeters	X	-	-
	maximumElevationInMeters	X	-	-
	decimalLatitude	X	X	X
	decimalLongitude	X	X	X
	country	X	-	-
	stateProvince	X	-	X
	county	X	-	X
	municipality	X	-	X
	locality	X	-	-
Taxonómica	Georreferenciación	-	-	X
	taxonRank	X	X	X
	scientificName	X	X	X
	kingdom	X	-	X
	phylum	X	-	X

	class	X	-	X
	order	X	-	X
	family	X	-	X
	genus	X	-	X
	specificEpithet	X	-	X
	infraspecificEpithet	X	-	-

Definición de parámetros de calidad

Compleitud: Evalúa el porcentaje de registros que contienen información documentada y disponible asociada a cada elemento DwC (Chapman, 2005).

Precisión: La precisión está definida como la proximidad entre los valores medidos obtenidos en mediciones repetidas de un mismo objeto, bajo condiciones especificadas (Comité Conjunto de Guías en Metrología, 2012).

Coherencia: Indica el nivel de cumplimiento de los vocabularios y formatos controlados en los estándares DwC (Chapman, 2005).

Tabla 02. Definición de parámetros de calidad medidos para cada elemento DwC.

Elemento DwC	Parámetro de calidad	Definición	Validación del dato	Valor cuantitativo
basisOfRecord (DwC 2013/2015)*	Coherencia Vocabulario	Vocabulario controlado establecido en las plantilla DwC 2013/2015	Válido	1
			Inválido	0
institutionID (NIT)*	Coherencia	Formato obligatorio del Número de Identificación Tributaria (NIT)	Válido	1
			Inválido	0
occurrenceID*	Coherencia Lógica	Todos los occurrenceID deben ser únicos.	id único	1
			id duplicado	0
eventDate	Precisión	Cantidad de componentes en la fecha, formato correcto 3 componentes (AAAA-MM-DD).	AAAA-MM-DD	1
			AAAA-MM	0.6
			AAAA	0.1
			Sin Fecha	0
eventDate*	Coherencia Formato	Formato de entrada correcto: Formato Fecha.	Válido	1
			Inválido	0
decimalLatitude/ decimalLongitude	Precisión Numérica	Cantidad de decimales significativos en la coordenada.	>= 4 decimales	1
			3 decimales	0.6
			<= 2 decimales	0.2
decimalLatitude/ decimalLongitude*	Coherencia Formato	Formato correcto de entrada: Coordenadas decimales	Válido	1
			Inválido	0

Elemento DwC	Parámetro de calidad	Definición	Validación del dato	Valor cuantitativo
Coordenadas + country + stateProvince + county (Georreferenciación)*	Coherencia	Coordenadas ubicadas espacialmente en el elemento geográfico registrado	Coordenadas Válidas	1
			Coordenadas Inválidas	0
stateProvince*	Coherencia	Oficialidad del nombre geopolítico según (DIVIPOLA)	Válido	1
county*			Inválido	0
municipality*			Inválido	0
taxonRank*	coherencia	Vocabulario controlado de la plantilla DwC.	Válido	1
			Inválido	0
	Precisión	El taxonRank registrado corresponde correctamente al scientificName registrado.	Válido	1
			Inválido	0
scientificName	Coherencia con árbol taxonómico GBIF	El scientificName registrado es validado por el árbol Taxonómico GBIF	EXACT	1.0
			FUZZY	0.6
			HIGHERRANK	0.3
			NONE	0
	Precisión	La precisión dependerá del máximo nivel de taxón identificado en el scientificName, teniendo en cuenta los siguientes niveles:	Especie	1.00
			Género	0.85
			Familia	0.70
			Orden	0.60
			Clase	0.45
			Filo/División	0.30
			Reino	0.15
kingdom, phylum, class, order, family, genus, specificEpithet*	Coherencia	Validado correctamente por el árbol Taxonómico GBIF	Válido	1
			Inválido	0

Aquellos elementos DwC identificados con (*) en la Tabla 02 significa que son de validación tipo Booleana, es decir se basa en valores de 1 y 0.

El elemento basisOfRecord es validado bajo dos estándares diferentes de coherencia, los datos originales son validados bajo los estándares de la plantilla DwC CR-SiB (2013) (SiB Colombia b), por otro lado, los datos procesados son validados con la plantilla DwC SiB (2015) (SiB Colombia c); esto se debe a que el vocabulario controlado para el elemento basisOfRecord es diferente en cada una de las plantillas.

Valoración de los parámetros de calidad aparente por Elemento DwC

Completitud:

Fórmula 01.

$$Completitud = \frac{\# \text{ de registros con información registrada}}{\# \text{ total de registros}} * 100$$

Precisión y Coherencia: Para los elementos de validación tipo booleana, especificados en la Tabla 02, se realizará el siguiente cálculo:

Fórmula 02.

$$V_{pc} = \frac{\# \text{ Registros válidos}}{\# \text{ total de registros}}$$

Donde:

- Vpc: Valor del parámetro de calidad para el Elemento DwC
- # de registros válidos: Cantidad de registros cuya validación de como resultado “1”
- # total de registros: Cantidad total de registros existentes en el conjunto de datos.

Para los elementos DwC restantes se establecieron cálculos ponderados para determinar lo valores de precisión y coherencia, de la siguiente forma:

- **eventDate**

Precisión

Fórmula 03.

$$P = \frac{(\#RB.AAAA - MM - DD * 1) + (\#RB.AAAA - MM * 0.6) + (\#RB.AAAA * 0.1)}{\# \text{ total de registros}}$$

Donde:

- P: valor de Precisión del elemento DwC para el conjunto de registros
- #RB. AAAA-MM-DD: Cantidad de registros con los tres componentes de la fecha registrados
- #RB. AAAA-MM: Cantidad de registros con solo dos componentes de la fecha registrados
- #RB. AAAA: Cantidad de registros con un solo componente de la fecha registrados

- **decimalLatitude/ decimalLongitude**

Precisión

Fórmula 04.

$$P = \frac{(\#RB. \geq 4 \text{ decimales} * 1) + (\#RB. 3 \text{ decimales} * 0.6) + (\#RB. \leq 2 \text{ decimales} * 0.2)}{\# \text{ total de registros}}$$

Donde:

- P: valor de Precisión del elemento DwC para el conjunto de registros
- #RB. ≥ 4 decimales: Cantidad de registros con 4 decimales o más en las coordenadas
- #RB. 3 decimales: Cantidad de registros con 3 decimales en las coordenadas
- #RB. ≤ 2 decimales: Cantidad de registros registrados con 2 decimales o menos en las coordenadas

- **scientificName**

Coherencia con árbol taxonómico de GBIF: Se identifica si la especie registrada está en la base de datos correspondiente al árbol taxonómico GBIF⁵.

Fórmula 05.

$$C_{ATG} = \frac{(\#RB.EXACT * 1) + (\#RB.FUZZY * 0.6) + (\#RB.HIGHERRANK * 0.2)}{\# \text{ total de registros}}$$

Donde:

- C_{ATG} : valor de coherencia del elemento DwC para el conjunto de registros
- $\#RB.EXACT$: Cantidad de registros validados como EXACT
- $\#RB.FUZZY$: Cantidad de registros validados como FUZZY
- $\#RB.HIGHERRANK$: Cantidad de registros validados como HIGHERRANK

Precisión

Fórmula 06.

$$P = \frac{(A * 1) + (B * 0.85) + (C * 0.7) + (D * 0.6) + (E * 0.45) + (F * 0.3) + (G * 0.15)}{\# \text{ total de registros}}$$

Donde:

- P: valor de precisión del elemento DwC para el conjunto de registros
- A: Cantidad de registros identificados al nivel: Especie, subespecie, variedad, subvariedad, forma, subforma
- B: Cantidad de registros identificados al nivel: Género, subgénero, Sección, SubSección, Serie, Subserie
- C: Cantidad de registros identificados al nivel: Familia, SubFamilia, Tribu, Subtribu
- D: Cantidad de registros identificados al nivel: Orden, Suborden
- E: Cantidad de registros identificados al nivel: Clase, Subclase
- F: Cantidad de registros identificados al nivel: Filo/División, Subfilo/subdivisión
- G: Cantidad de registros identificados al nivel: Reino, Subreino

Valoración de los parámetros de calidad para cada categoría

Teniendo en cuenta que los elementos DwC tienen diferente relevancia dentro de las correspondientes categorías, es necesario definir un peso ponderado para cada elemento DwC, de esta forma, cuanto mayor sea la relevancia del elemento DwC dentro de la categoría, mayor será su peso ponderado. Para la definición de los pesos ponderados se tomó como referencia el documento Índice de Calidad Aparente (ICA) en Darwin Test (GBIF España, 2017).

⁵ <https://www.gbif.org/dataset/d7dddbf4-2cf0-4f39-9b2a-bb099caae36c#description>

- **Registro.**

- **Compleitud:** El parámetro de completitud es el resultado de calcular el promedio de los valores de completitud de cada uno de los elementos DwC que componen la categoría Registro.

- **Coherencia:**

Fórmula 07.

$$Coh = OI * 0.6 + II * 0.2 + BR * 0.2$$

Donde:

- Coh: valor de coherencia para la categoría Registro
- OI: Valor de coherencia del Elemento DwC occurrenceID
- II: Valor de coherencia del Elemento DwC institutionID
- BR: Valor de Coherencia del Elemento DwC basisOfRecord

- **Temporal.**

Los valores de los parámetros de calidad para la categoría temporal son los mismo obtenidos para el elemento DwC eventDate, dichos valores son obtenidos a partir de las fórmulas: Completitud (Fórmula 01), Precisión (Fórmula 03), Coherencia (Fórmula 02).

- **Geográfica:**

- **Compleitud:** El parámetro de completitud es el resultado de calcular el promedio de los valores de completitud de cada uno de los elementos DwC que componen la categoría geográfica, exceptuando el elemento Georreferenciación, al cual no se le mide el parámetro de completitud, ya que dicho elemento no hace parte de las plantillas DwC.

- **Precisión:**

Fórmula 08.

$$P = DLa * 0.5 + DLo * 0,5$$

Donde:

- P: Valor de precisión de la categoría geográfica
- DLa: Valor de precisión del elemento DwC decimalLatitude
- DLo: Valor de precisión del elemento DwC decimalLongitude

- **Coherencia**

Fórmula 09.

$$Coh = GR * 0.5 + SP * 0.15 + CTY * 0.15 + MU * 0.1 + DLa * 0.05 + DLo * 0.05$$

Donde:

- Coh: Valor de coherencia para la categoría geográfica
- GR: Valor de coherencia del elemento Georreferenciación
- SP: Valor de coherencia del elemento DwC stateProvince

- CTY: Valor de coherencia del elemento DwC county
- MU: Valor de coherencia del elemento DwC municipality
- DLa: Valor de coherencia del elemento DwC decimalLatitude
- DLo: Valor de coherencia del elemento DwC decimalLongitude

- **Taxonómica:**

- **Compleitud:** El parámetro de completitud es el resultado de calcular el promedio de los valores de completitud de cada uno de los elementos DwC que componen la categoría taxonómica.

- **Precisión:**

Fórmula 10.

$$P = SN * 0.6 + TR * 0.4$$

Donde:

- P: Valor de precisión para la categoría taxonómica
- SN: Valor de precisión del elemento DwC scientificName
- TR: Valor de precisión del elemento DwC taxonRank

- **Coherencia:**

Fórmula 11.

$$Coh = SN * 0.4 + TR * 0,25 + VCT$$

Donde:

- Coh: Valor de coherencia para la categoría taxonómica
- SN: Valor de coherencia del elemento DwC scientificName
- TR: Valor de coherencia del elemento DwC taxonRank
- VCT: Valor de coherencia de los taxones.

Fórmula 12.

$$VCT = K * 0.05 + P * 0.05 + C * 0.05 + O * 0.05 + F * 0.05 + G * 0.05 + SE * 0.05$$

Donde:

- VCT: Valor de coherencia de los taxones.
- K: Valor de coherencia del Elemento DwC kingdom
- P: Valor de coherencia del Elemento DwC phylum
- C: Valor de coherencia del Elemento DwC class
- O: Valor de coherencia del Elemento DwC order
- F: Valor de coherencia del Elemento DwC family
- G: Valor de coherencia del Elemento DwC genus
- SE: Valor de coherencia del Elemento DwC specificEpithet

Valoración de calidad aparente para cada categoría

Con los parámetros de calidad para cada una de las categorías de información se realiza el cálculo de calidad aparente general para cada categoría, teniendo en cuenta los pesos ponderados otorgados a cada parámetro de calidad, como se muestra en la Tabla 03.

Tabla 03. Pesos Ponderados de los parámetros de calidad para cada una de las categorías

Categoría	Peso ponderado Compleitud	Peso ponderado Precisión	Peso ponderado Coherencia
Registro	0.8	-	0.2
Temporal	0.3	0.5	0.2
Geográfica	0.2	0.2	0.6
Taxonómica	0.3	0.35	0.35

- **Registro**

Fórmula No 13.

$$CCR = CoCR * 0.8 + CohCR * 0.2$$

Donde:

- CCR: Valor de calidad aparente de la categoría registro
- CoCR: Valor de completitud de la categoría registro
- CohCR: Valor de coherencia de la categoría registro

- **Temporal**

Fórmula No 14.

$$CCTe = PCTe * 0.5 + CoCTe * 0.3 + CohCTe * 0.2$$

Donde:

- CCTe: Valor de calidad aparente de la categoría temporal
- PCTe: Valor de precisión de la categoría temporal
- CoCTe: Valor de completitud de la categoría temporal
- CohCTe: Valor de coherencia de la categoría temporal

- **Geográfica**

Fórmula No 15.

$$CCGeo = CohGeo * 0.6 + CoGeo * 0.2 + PGeo * 0.2$$

Donde:

- CCGeo: Valor de calidad aparente de la categoría geográfica
- CohGeo: Valor de coherencia de la categoría geográfica
- CoGeo: Valor de completitud de la categoría geográfica
- PGeo: Valor de precisión de la categoría geográfica

- **Taxonómica**

Fórmula No 16.

$$CCTa = CohTa * 0.35 + PTa * 0.35 + CoTa * 0.3$$

Donde:

- CCTa: Valor de calidad aparente de la categoría taxonómica
- CohTa: Valor de coherencia de la categoría taxonómica
- PTa: Valor de precisión de la categoría taxonómica
- CoTa: Valor de completitud de la categoría taxonómica

Valoración de calidad aparente ICA para el conjunto de datos.

Finalmente se realiza el cálculo para determinar el valor de calidad aparente general para el conjunto de datos, de la siguiente forma.

Fórmula No 17.

$$ICA = CCTa * 0.35 + CCGeo * 0.3 + CCTe * 0.2 + CCR * 0.15$$

Donde:

- ICA: Valor del Índice de Calidad Aparente del conjunto de datos
- CCTa: Valor de calidad aparente de la categoría taxonómica
- CCGeo: Valor de calidad aparente de la categoría geográfica
- CCTe: Valor de calidad aparente de la categoría temporal
- CCR: Valor de calidad aparente de la categoría registro

Publicación de recursos

En la plataforma de publicación SiB Colombia (<https://ipt.biodiversidad.co/sib/>) se realizará la publicación de los datos, inicialmente se importará el recurso dwc-a extraído del modelos CR-SiB, de esta forma los metadatos y datos serán mapeados en el modelo de publicación SiB, luego, se eliminan los datos originales y se cargan los datos procesados, estos se mapean bajo el estándar DwC, posteriormente se realizará la actualización de los metadatos, allí se actualizará la información respecto a cobertura geográfica, temporal y taxonómica, así mismo, en el apartado Palabras Clave se documentara el Tesauro “SiB Colombia” y la palabra clave “PERMISO_COLECTA”, finalmente en el apartado Enlaces Externos se agregara el enlace al modelo CR.SiB donde están los datos originales, esto con el fin de tener una óptima trazabilidad de la información.

5. Resultados.

Contextualización marco normativo

Tabla 04. Principales documentos utilizados en la etapa de contextualización.

Norma	Elementos relevantes
Decreto 1376 de 2013	- “Por el cual se reglamenta el permiso de recolección de especímenes de especies silvestres de la diversidad biológica con fines de investigación científica no comercial”. - Capítulo II, Artículo 9 Obligaciones del titular del permiso, inciso e) Suministrar al Sistema de Información de Biodiversidad de Colombia la información asociada a los especímenes recolectados y entregar a la autoridad competente la constancia emitida por dicho sistema.
Decreto 3016 de 2013	- Por el cual se reglamenta el Permiso de estudio para la recolección de especímenes de especies silvestres de la diversidad biológica con fines de elaboración de Estudios Ambientales. - Artículo 6 Obligaciones, Numeral 6. Terminado el estudio, el titular del permiso deberá reportar al sistema de Información sobre Biodiversidad de Colombia la información asociada a los especímenes recolectados, y entregar a la autoridad ambiental la constancia emitida por dicho sistema.
Decreto 1603 de 1994	- Por el cual se organizan y establecen los institutos de Investigación de Recursos Biológicos “Alexander Von Humboldt”, el Instituto Amazónico de Investigaciones “SINCHI” y el Instituto de Investigaciones Ambientales del Pacífico “John Von Neumann”.
Decreto 1008 de 2018	- Por el cual se establecen los lineamientos generales de la Política de Gobierno Digital y se subroga el capítulo 1 del título 9 de la parte 2 del libro 2 del Decreto 1078 de 2015, Decreto Único reglamentario del sector de Tecnología de la información y las comunicaciones.

Resultados Colección de Zoología General de la Universidad de Pamplona (ZOO)

La Colección de Zoología General de la Universidad de Pamplona (ZOO) contiene un total de 1548 registros biológicos recolectados en los Departamentos Norte de Santander y Santander, documentados entre las fechas 2010-10-21 a 2019-06-29, en la identificación taxonómica de los registros biológicos se establecieron 32 órdenes diferentes, de los cuales el 81.39% de los registros se identificaron a nivel de epíteto específico (SiB Colombia, 2019e). (Tabla 05 y 06) Presenta la información general y los resultados del ICA de los datos, (tabla 07) presenta los resultados por cada parámetro de calidad donde A son los datos originales y B los datos procesados.

Tabla 05. Información General de la Colección de Zoología General de la Universidad de Pamplona.

Información General					
Conjunto de Datos		Colección de Zoología General de la Universidad de Pamplona (ZOO)			
Número de registros		1548			
Entidad publicadora		Universidad de Pamplona			
Fecha de publicación		2019-09-19			
Enlace DOI		https://doi.org/10.15472/qmwz8a			
Calidad del Conjunto de Datos					
ICA datos originales	0.70	ICA datos procesados	0.90	Porcentaje de Mejora (%)	19.78

Tabla 06. Resultados calidad aparente por categoría y totalidad del conjunto de datos de la Colección de Zoología General de la Universidad de Pamplona (ZOO).

Categoría DwC	Calidad aparente datos originales	Calidad aparente datos procesados	Porcentaje de Mejora (%)
Registro	0.88	0.93	4.71
Temporal	0.36	1	63.8
Geográfica	0.88	0.91	3.27
Taxonómica	0.67	0.82	15.22
Conjunto Datos	0.70	0.90	19.78

Tabla 07. Resultados calidad aparente de cada parámetro medido por categoría para los datos originales y datos procesados.

Categoría DwC	Complejidad			Precisión			Coherencia		
	A	B	Mejora (%)	A	B	Mejora (%)	A	B	Mejora (%)
Registro	89.87	90.76	0.89	-	-	-	0.8	1	20
Temporal	100	100	0	0.09	1	91	0.09	1	91
Geográfica	87.73	87.73	0	1	1	0	0.83	0.89	6
Taxonómica	88.22	88.22	0	0.51	0.65	14	0.65	0.94	29

Resultados Colección Flora del Nororiente Colombiano: Colecciones del Herbario Regional Catatumbo Sarare (HECASA).

La Colección Flora del Nororiente Colombiano: Colecciones del Herbario Regional Catatumbo Sarare (HECASA) contiene un total de 2735 registros biológicos recolectados en diferentes municipios del departamento Norte de Santander entre las fechas 1997-11-01 a 2019-08-30, para los cuales se identificaron 61 órdenes distribuidos en 170 familias, de los cuales se logró identificar el 41.27% a nivel de epíteto específico y el 55.21% a nivel de género (SiB Colombia, 2019f). La información general, resultados del ICA de los datos originales y procesados pueden observarse en las tablas 08 y 09, en la tabla 10 se presentan los resultados por cada parámetro de calidad donde A son los datos originales y B los datos procesados.

Tabla 08. Información General Colecciones del Herbario Regional Catatumbo Sarare.

Información General					
Conjunto de Datos	Flora del Nororiente Colombiano: Colecciones del Herbario Regional Catatumbo Sarare (HECASA)				
Número de registros	2735				
Entidad publicadora	Universidad de Pamplona				
Fecha de publicación	2019-09-19				
Enlace DOI	https://doi.org/10.15472/wn1rtp				
Calidad del Conjunto de Datos					
ICA datos originales	0.64	ICA datos procesados	0.92	Porcentaje de Mejora (%)	28.0

Tabla 09. Resultados calidad aparente por categoría y totalidad del conjunto de datos de la Flora del Nororiente Colombiano: Colecciones del Herbario Regional Catatumbo Sarare (HECASA).

Categoría DwC	Calidad aparente datos originales	Calidad aparente datos procesados	Porcentaje de Mejora (%)
Registro	0.69	0.97	27.57
Temporal	0.55	0.99	43.81
Geográfica	0.7	0.89	18.7
Taxonómica	0.61	0.89	27.46
Conjunto Datos	0.64	0.92	28

Tabla 10. Resultados calidad aparente de cada parámetro medido por categoría para los datos originales y datos procesados.

Categoría DwC	Complejidad			Precisión			Coherencia		
	A	B	Mejora (%)	A	B	Mejora (%)	A	B	Mejora (%)
Registro	68.65	96.25	27.6	-	-	-	0.73	1	27
Temporal	99.01	99.05	0.04	0.36	0.99	63	0.36	0.99	63
Geográfica	73.48	83.51	10.03	0.65	0.97	32	0.71	0.87	16
Taxonómica	80.31	83.82	3.51	0.48	0.95	46	0.58	0.87	29

Resultados recurso Onicóforos de la Sierra Nevada de Santa Marta.

El recurso Onicóforos de la Sierra Nevada de Santa Marta contiene un total de 4 registros biológicos recolectados en las inmediaciones de la Sierra Nevada de Santa Marta entre las fechas 2017-09-22 a 2017-09-25, para los cuales se identificaron 4 ejemplares del filo Onychophora del género Epiperipatus (SiB Colombia, 2019g). La información general, resultados del ICA de los datos originales y procesados pueden observarse en las tablas 11 y 12, en la tabla 13 se presentan los resultados por cada parámetro de calidad donde A son los datos originales y B los datos procesados.

Tabla 11. Información General del conjunto de datos Onicóforos de la Sierra Nevada de Santa Marta.

Información General					
Conjunto de Datos		Onicóforos de la Sierra Nevada de Santa Marta			
Número de registros		4			
Entidad publicadora		Universidad de Magdalena			
Fecha de publicación		2019-10-07			
Enlace DOI		https://doi.org/10.15472/lhjlei			
Calidad del Conjunto de Datos					
ICA datos originales	0.53	ICA datos procesados	0.89	Porcentaje de Mejora (%)	35.34

Tabla 12. Resultados calidad aparente por categoría y totalidad del conjunto de datos Onicóforos de la Sierra Nevada de Santa Marta.

Categoría DwC	Calidad aparente datos originales	Calidad aparente datos procesados	Porcentaje de Mejora (%)
Registro	0.68	1	32
Temporal	1	1	0
Geográfica	0.6	0.9	30
Taxonómica	0.15	0.77	61.54
Conjunto Datos	0.53	0.89	35.34

Tabla 13. Resultados calidad aparente de cada parámetro medido por categoría para los datos originales y datos procesados.

Categoría DwC	Complejidad			Precisión			Coherencia		
	A	B	Mejora (%)	A	B	Mejora (%)	A	B	Mejora (%)
Registro	70	100	30	-	-	-	0.6	1	40
Temporal	100	100	0	1	1	0	1	1	0
Geográfica	80	80	0	1	1	0	0.4	0.9	50
Taxonómica	50	60	10	0	0.91	91	0	0.76	76

Resultados recurso Tardígrados del Centro de Colecciones Biológicas de la Universidad del Magdalena CBUMAG

El recurso Tardígrados del Centro de Colecciones Biológicas de la Universidad del Magdalena CBUMAG contiene un total de 11360 registros biológicos recolectados en los Departamentos de Magdalena y Cesar, entre las fechas 2011-11-07 a 2017-06-29, para los cuales se identificaron 6 familias diferentes y se logró identificar el 48.18% a nivel de género. La información general, resultados del ICA de los datos originales y procesados pueden observarse en las tablas 14 y 15, en la tabla 16 se presentan los resultados por cada parámetro de calidad donde A son los datos originales y B los datos procesados.

Tabla 14. Información General del conjunto de datos

Información General					
Conjunto de Datos	Tardígrados del Centro de Colecciones Biológicas de la Universidad del Magdalena CBUMAG				
Número de registros	11360				
Entidad publicadora	Universidad de Magdalena				
Fecha de publicación	2019				
Enlace DOI	En proceso				
Calidad del Conjunto de Datos					
ICA datos originales	0.88	ICA datos procesados	0.91	Porcentaje de Mejora (%)	2.71

Tabla 15. Resultados calidad aparente por categoría y totalidad del conjunto de datos Tardígrados del Centro de Colecciones Biológicas de la Universidad del Magdalena CBUMAG

Categoría DwC	Calidad aparente datos originales	Calidad aparente datos procesados	Porcentaje de Mejora (%)
Registro	0.88	0.92	4
Temporal	1	1	0
Geográfica	0.93	0.99	5.91
Taxonómica	0.78	0.79	0.97
Conjunto Datos	0.88	0.91	2.71

Tabla 16. Resultados calidad aparente de cada parámetro medido por categoría para los datos originales y datos procesados.

Categoría DwC	Complejidad			Precisión			Coherencia		
	A	B	Mejora (%)	A	B	Mejora (%)	A	B	Mejora (%)
Registro	90	90	0	-	-	-	0.8	1	20
Temporal	100	100	0	1	1	0	1	1	0
Geográfica	99.89	99.89	0	1	1	0	0.89	0.99	10
Taxonómica	67.86	67.88	0.02	0.78	0.78	0	0.86	0.88	2

6. Discusión y Conclusiones

Colección (ZOO) y (HECASA).

El proceso de validación y migración de datos de las colecciones **ZOO** y **HECASA** lograron mejorar el índice de calidad aparente en un **19.76%** y **28%** respectivamente, esto se debe principalmente a los ajustes realizados sobre las categorías temporal y taxonómica (tablas 06 y 09).

En la categoría temporal se encontró que en 1411 registros de la colección ZOO y 1738 registros de la colección HECASA, el elemento eventDate se documentó con errores en el formato controlado, tras realizar la documentación con el formato correcto de fecha (AAAA-MM-DD) se logró mejorar la calidad aparente de esta categoría en **91%** para la colección ZOO y **43.81%** para la colección HECASA. En cuanto a la categoría taxonómica se encontró que la Colección ZOO tuvo una mejora del **15.22%** y la colección HECASA del **27%**, esto se debe a los ajustes realizados sobre los elementos DwC taxonRank, scientificName, kingdom, phylum class, family y genus.

En la categoría registro se evidenció una mejora del **20%** y **27%** en las colecciones ZOO y HECASA respectivamente, esto se debe a los ajustes realizados sobre el elemento institutionID, documentando correctamente el formato del Número de Identificación Tributaria (NIT).

Finalmente se tiene la categoría geográfica, la cual presentó los menores % de mejora con 6% para colección ZOO y 18.3% para la colección HECASA.

Recursos Onicóforos de la Sierra Nevada de Santa Marta y Tardígrados del Centro de Colecciones Biológicas de la Universidad del Magdalena CBUMAG .

La validación, limpieza y migración de los recursos Onicóforos de la Sierra Nevada de Santa Marta y Tardígrados del Centro de Colecciones Biológicas de la Universidad del Magdalena CBUMAG, mejoró el ICA de los recursos en **35.34%** y **2.71%** respectivamente (tablas 12 y 15). En el recurso Onicóforos

de la Sierra Nevada de Santa Marta el mayor porcentaje de mejora se logró en la **categoría taxonómica** con una mejora del **61.54%**, gracias a los ajustes realizados sobre los elementos taxonRank, scientificName, kingdom, phylum y genus, logrando mejorar la precisión y coherencia taxonómica en 91% y 76% respectivamente.

En cuanto al recurso Tardígrados del Centro de Colecciones Biológicas de la Universidad del Magdalena CBUMAG el mayor porcentaje de mejora se logró en la **categoría geográfica** con un **5.61%** debido a los ajustes realizados sobre el elemento municipality, estos ajustes permitieron una mejora del 10% en la coherencia geográfica de los datos.

Conclusiones

- La validación, manejo y migración de los datos de la colección de Zoología General de la Universidad de Pamplona (**ZOO**) logró mejorar el índice de calidad aparente de los datos en un **19.78%**. En cuanto a la Colección Flora de Nororiente Colombiano, Colecciones del Herbario Regional Catatumbo Sarare (**HECASA**) se logró una mejora del **28%** en el índice de calidad aparente.
- El proceso de validación, limpieza y migración de los recursos **Onicóforos de la Sierra Nevada de Santa Marta** y **Tardígrados del Centro de Colecciones Biológicas de la Universidad del Magdalena CBUMAG** permitieron mejorar el índice de calidad aparente de los datos en un **35.34%** y **2.71%** respectivamente.
- En las colecciones ZOO y HECASA, el elemento que presentó los menores valores de calidad aparente en los datos originales fue el eventDate, esto se debe al formato de documentación original, el elemento fue registrado en formato Numérico y no en formato Fecha (AAAA-MM-DD).
- El proceso de validación, manejo y migración de los datos de la Universidad de Pamplona y universidad de magdalena, aportó la inclusión de una nueva organización publicadora, permitió la reconstrucción de 2 colecciones biológicas de la Universidad de Pamplona, y la publicación **15.674 registros biológicos**, estos datos cuentan con un índice de calidad aparente alto lo cual aumenta la cantidad de usuarios que pueden utilizar los datos.
- Los 4 recursos publicados a través del modelo SiB Colombia ahora hacen parte de las bases de datos mediadas por GBIF lo cual aumenta en gran medida la visibilidad de los datos permitiendo que esta información sea consultada a nivel internacional, de esta manera los datos publicados aportan al posicionamiento del SiB Colombia en su participación en las bases de datos GBIF. Así mismo estos datos representan una nueva base de información de alta calidad que puede ser utilizada en la construcción de líneas base para estudios ambientales a nivel nacional, de esta forma los proyectos desarrollados en el país tendrán una visión más clara y sólida del estado real de la biodiversidad en el país, esto aporta al cumplimiento de los objetivos de la Política de Gobierno Digital establecida en el Decreto 1078 de 2015, la cual busca fomentar la toma de decisiones basada en los datos, la provisión de servicios digitales y la transferencia de información entre diferentes entidades.

7. Recomendaciones

- La validación, manejo y migración de los datos debe realizarse en grandes grupos de datos, esto facilita la gestión de los datos y generará un ahorro de tiempo en el proceso de

validación y limpieza de los datos, para esto es necesario identificar las posibles agrupaciones realizar para los conjuntos de datos de una misma organización publicadora.

- Es necesario verificar los formatos de documentación de los datos en los elementos eventDate, decimalLatitude y decimalLongitude antes de ser publicados a través de cualquiera de los modelos de publicación, ya que estos elementos son registrados erróneamente esto puede suceder debido a la conversión o manejo de archivos de texto plano en los cuales están los datos originalmente.
- Es necesario establecer de la manera más clara y específica la trazabilidad de los datos, esto facilitará la migración de la información, ya que será más sencillo obtener información de los metadatos o recuperar información de los datos que puede ser útil en la validación y limpieza.

8. Metas e indicadores

- Se planteó como meta realizar la validación, limpieza y publicación de los conjuntos de datos pertenecientes a la Universidad de Pamplona y Universidad de Magdalena, esto se cumplió realizando la publicación en el modelo SiB Colombia de 2 recursos de la Universidad de Pamplona y 2 recursos de la Universidad de Magdalena.
- En segundo lugar, se planteó como meta desarrollar 2 documentos asociados al proceso de migración realizado por el EC-SiB, correspondientes a la creación de los documentos: Metodología para la cuantificación del índice de calidad aparente y migración de los datos en el modelo de publicación certificado de reporte, y al Reporte de migración de datos, los cuales fueron desarrollados en su totalidad.

9. Referencias

- Chapman, A. D. (2005). *Principles of Data Quality*. Obtenido el 26 de septiembre de 2019 de: <https://www.gbif.org/document/80509/principles-of-data-quality>
- Comité Conjunto de Guías en Metrología. (2012). *Vocabulario Internacional de metrología. Conceptos fundamentales y generales, y términos asociados*. Obtenido el 26 de septiembre de 2019 de: <https://www.cem.es/sites/default/files/vim-cem-2012web.pdf>
- GBIF España. (2017). *Índice de Calidad Aparente (ICA) en Darwin Test*. Obtenido el 02 de octubre del 2019 de: https://www.gbif.es/wp-content/uploads/2017/12/ICA_ES_EN.pdf
- GBIF Secretariat. (2019). *GBIF Science Review 2019*. Obtenido el 02 de octubre del 2019 de: <https://doi.org/10.15468/QXXG-7K93>
- Ministerio de Ambiente y Desarrollo Sostenible. (27 de diciembre de 2013). *Decreto 3016 de 2013*. Obtenido el 26 de septiembre de 2019 de: http://www.minambiente.gov.co/images/normativa/Decretos/2013/dec_3016_2013.pdf
- Ministerio de Tecnologías de la Información y Comunicaciones. (14 de junio de 2018). *Decreto 1008 de 2018*. Obtenido el 26 de septiembre de 2019 de: <https://www.mintic.gov.co/portal/inicio/74903:Decreto-1008-del-14-de-junio-de-2018>
- SiB Colombia. (diciembre de 2016). *Manual de Identidad*. Obtenido el 27 de septiembre de 2019 de: <http://repository.humboldt.org.co/handle/20.500.11761/35037>
- SiB Colombia. (2018a). *Modelo de reporte de datos asociados a permisos de recolección de acuerdo a los Decretos 1376 y 3016 de 2013 - CR.SiB*. Obtenido el 26 de septiembre de 2019 de: <http://repository.humboldt.org.co/handle/20.500.11761/35170>
- SiB Colombia. (Septiembre de 2018b). *Diagnóstico de calidad para los datos publicados en CR-SiB período 2014-2016*. Bogotá D.C.
- SiB Colombia. (Julio de 2019b). *OpenRefine - Guía de validación y limpieza de datos sobre biodiversidad*. Obtenido el 03 de octubre del 2019 de: <http://hdl.handle.net/20.500.11761/35350>
- SiB Colombia. (2019). *Sistema de Información Sobre Biodiversidad de Colombia -SiB Colombia*. Obtenido de Biodiversity data quality Scripts in Open Refine el 02 de octubre del 2019 de: <https://github.com/SiB-Colombia/data-quality-open-refine>

SiB Colombia. (2019e). *Colección de Zoología General de la Universidad de Pamplona*.

Obtenido el 08 de octubre del 2019 de:

https://ipt.biodiversidad.co/sib/resource?r=museo_upamplona

SiB Colombia. (2019f). *Flora del Nororiente Colombiano: Colecciones del Herbario Regional Catatumbo Sarare*. Obtenido el 08 de octubre del 2019 de:

https://ipt.biodiversidad.co/sib/resource?r=hecasa_upamplona

SiB Colombia. (2019g). *Onicóforos de la Sierra Nevada de Santa Marta*. Obtenido el 27 de octubre de 2019 de:

https://ipt.biodiversidad.co/sib/resource?r=onicoforossnm_1293

SiB Colombia b. (s.f.). *Wiki SiB Colombia*. Obtenido el 05 de octubre del 2019 de Plantilla

CR-SiB: <https://sites.google.com/humboldt.org.co/wikisib/reportar/plantilla-cr-sib>

SiB Colombia c. (s.f.). *Wiki SiB Colombia*. Obtenido el 05 de octubre del 2019 de Colecciones:

<https://sites.google.com/humboldt.org.co/wikisib/publicar/colecciones>

Anexos

Anexo 01. Conjuntos de Datos Universidad de Pamplona seleccionados para la migración.

Colección	Nombre conjunto de datos	# R. biológicos
Colección de Zoología General de la Universidad de Pamplona (ZOO)	Diversidad filogenética de las especies de anfibios y mariposas diurnas en los páramos del Complejo Almorzadero en Norte de Santander, Colombia	1078
	Diversidad filogenética de las especies de anfibios y mariposas diurnas en los páramos del Complejo Almorzadero en Norte de Santander, Colombia	73
	Caracterización de la fauna silvestre de Norte de Santander	34
	Entomología Universidad de Pamplona*	99
	Museo Universidad de Pamplona*	38
	Aportes preliminares al conocimiento de la fauna silvestre del Norte de Santander	39
	Aportes preliminares al conocimiento de la fauna silvestre del Norte de Santander	13
	Aportes al conocimiento de la fauna nororiental colombiana.	109
Flora del Nororiente Colombiano Colecciones del Herbario Regional Catatumbo Sarare (HECASA)	Aportes al conocimiento de la fauna nororiental colombiana	65
	Aportes al conocimiento de la flora de Norte de Santander	198
	Aportes al conocimiento de la flora del nororiente colombiano	445
	Aportes a la flora de Norte de Santander	585
	Herbario Universidad de Pamplona*	104
	Ericales Norte de Santander Universidad de Pamplona*	921
	Aportes a la flora de Norte de Santander	482
Total		4283